

UNIVERSITÀ DEGLI STUDI DI CAGLIARI

Corso di Laurea Magistrale

Insegnamento di Big Data

Pipeline Big Data per il monitoraggio IoT ambientale e il rilevamento di incendi

Relazione di progetto

Docente

Prof. Diego Reforgiato Recupero

Studenti

Alessandro Piras — Federico Basciu

Anno Accademico 2025/2026

Indice

1. Obiettivo del progetto.....	3
2. I dati.....	3
2.1 Origine e natura.....	3
2.2 Cosa contiene una lettura	3
2.3 Informazioni aggiunte quando il dato entra nella pipeline	3
3. Che cosa è clusterizzato	4

3.1 I tre cluster del sistema	4
3.2 Perché Kafka è replicato su tre nodi.....	4
3.3 Perché Spark ha tre worker	4
4. Come si spostano i dati.....	4
5. Come vengono trattati i dati in Spark.....	5
5.1 Conservazione del dato grezzo	5
5.2 Pulizia	5
5.3 Rilevamento di anomalie.....	5
5.4 Segnalazione degli incendi	6
5.5 Riepiloghi su finestre temporali	6
6. Dove finiscono i dati: architettura Lambda	6
6.1 Il percorso batch (analisi storica).....	6
7. Validazione del rilevamento	7
8. Le dashboard	7
8.1 Vista globale (IoT Sensor Dashboard).....	7
8.2 Dettaglio per nodo (IoT Node Detail)	7
8.3 Mappa incendi (Mappa Incendi)	8
8.4 Vista storica (IoT Storico — Batch Layer)	8
9. Sintesi	8

1. Obiettivo del progetto

L'obiettivo è realizzare una pipeline Big Data end-to-end, interamente containerizzata, che acquisisce in tempo reale i dati di quattro nodi sensore IoT ambientali, li elabora in streaming con rilevamento di anomalie e di incendi, e li rende disponibili su dashboard live aggiornate ogni pochi secondi.

Il caso d'uso applicativo è l'early warning di incendi in ambiente boschivo a partire da sensori di gas, fumo, temperatura e qualità dell'aria. L'aspetto centrale, su cui si concentra questa relazione, è che il sistema non gira su un singolo processo: è distribuito su più nodi clusterizzati e i dati attraversano una catena di componenti, ciascuno con un ruolo preciso.

2. I dati

2.1 Origine e natura

I dati provengono da acquisizioni reali effettuate con nodi sensore fisici (Raspberry Pi) in condizioni diverse: scenari normali e scenari di combustione controllata (ad esempio aghi di pino). Ogni nodo ha prodotto un file CSV; nella pipeline ciascun nodo è simulato come una macchina separata che pubblica le proprie letture.

I nodi sono quattro, per un totale di 6 741 letture reali. Ogni nodo viene riprodotto in loop continuo: il flusso verso la pipeline è quindi, di fatto, illimitato.

Nodo	Letture	Etichetta Fire	Note
nodo_1	1 732	sì	scenari misti (normale + combustione)
nodo_2	1 731	sì	acquisizione interamente in combustione
nodo_3	1 668	sì	scenari misti, include anche il livello Fire = 2
nodo_4	1 610	no	nessuna colonna Fire: caso non etichettato
Totale	6 741		

Tabella 1 — Composizione del dataset reale (una riga per lettura).

2.2 Cosa contiene una lettura

Ogni lettura (e quindi ogni messaggio che viaggia nella pipeline) porta con sé le grandezze ambientali misurate: temperatura, umidità, pressione, resistenza del sensore di gas (che cala in presenza di volatili e fumo), luce visibile, infrarosso, indice UV, monossido di carbonio (CO), biossido di azoto (NO2) e fumo. Le letture etichettate hanno in più il campo Fire, che vale 0 in condizioni normali e 1 o più durante un incendio.

Il campo Fire funge da verità di riferimento per validare il rilevamento. È presente su nodo_1, nodo_2 e nodo_3, ma assente su nodo_4: quest'ultimo viene quindi usato come caso non etichettato, su cui la detection lavora comunque ma che resta escluso dalla validazione.

2.3 Informazioni aggiunte quando il dato entra nella pipeline

Nel momento in cui una lettura viene pubblicata, il sistema le aggiunge tre informazioni che servono a farla viaggiare e ritrovare lungo tutta la catena: il nodo di provenienza, un indice progressivo della lettura e un istante temporale (timestamp). Quest'ultimo è particolarmente importante, perché è il riferimento di tempo usato più avanti per raggruppare i dati in finestre temporali.

3. Che cosa è clusterizzato

Il sistema è composto da diciannove servizi orchestrati con Docker Compose (di questi, il componente di analisi storica si avvia solo su richiesta). Sono progettati e configurati come se girassero su macchine separate: comunicano per nome di rete, come farebbero host fisici distinti. Tre componenti sono veri e propri cluster a più nodi; gli altri sono servizi singoli di supporto.

3.1 I tre cluster del sistema

Il cuore distribuito del progetto sono tre cluster, riassunti nella Tabella 2.

Componente	Nodi	A cosa serve la clusterizzazione
Broker di messaggi (Kafka)	3 broker	Bufferizza i messaggi in arrivo dai sensori e li conserva in modo ridondante. Ogni dato è replicato su 3 nodi: se un broker cade, nessun messaggio va perso e la pipeline continua a funzionare.
Motore di elaborazione (Spark)	1 master + 3 worker	Esegue l'elaborazione in parallelo. Il master coordina e distribuisce il lavoro; i tre worker elaborano i dati contemporaneamente. La logica per nodo gira sui worker, non su un punto unico.
Sorgenti dati (producer)	4 producer	Ogni nodo sensore è un processo separato che pubblica le proprie letture in modo indipendente dagli altri, esattamente come quattro macchine sul campo.

Tabella 2 — I componenti clusterizzati e il motivo della clusterizzazione.

Accanto ai cluster ci sono i servizi di archiviazione e visualizzazione: un database documentale (MongoDB) che conserva lo storico e gli stati, un motore di ricerca e serie temporali (Elasticsearch) che alimenta i cruscotti, e lo strumento di dashboard (Grafana). A questi si aggiungono alcune interfacce di amministrazione per ispezionare Kafka e MongoDB.

3.2 Perché Kafka è replicato su tre nodi

Il topic su cui transitano le letture è suddiviso in quattro partizioni (una per nodo sensore) e ogni partizione è replicata su tre broker, con il vincolo che almeno due copie siano sempre allineate prima di confermare la scrittura. Questa è la garanzia di tolleranza ai guasti del sistema: si può spegnere dal vivo un broker e la pipeline continua a ricevere ed elaborare dati senza perdite. È una proprietà dimostrabile durante la presentazione.

3.3 Perché Spark ha tre worker

Suddividere i dati per nodo permette di assegnare ogni nodo a un worker diverso e di elaborarli in parallelo. L'elaborazione che richiede di tenere memoria del passato (per esempio il calcolo statistico incrementale su ciascun sensore) viene eseguita direttamente sui worker e non viene mai riportata interamente a un punto centrale: questo è ciò che rende l'elaborazione realmente distribuita e non un semplice programma eseguito su una macchina sola.

4. Come si spostano i dati

Il percorso del dato, dalla sorgente alla dashboard, attraversa cinque tappe. Ogni freccia rappresenta un passaggio di dati tra componenti che, nel progetto, sono trattati come macchine distinte.

4 nodi sensore → Kafka (3 broker) → Spark (master + 3 worker) → MongoDB + Elasticsearch → Grafana

Figura 1 — Il percorso dei dati dalla sorgente alle dashboard.

1. Dalla sorgente al broker. Ognuno dei quattro nodi pubblica le proprie letture sul cluster Kafka. Ogni nodo scrive su una partizione dedicata: in questo modo l'ordine delle letture di uno stesso nodo è sempre rispettato, cosa indispensabile per le elaborazioni che dipendono dalla sequenza temporale.

2. Dal broker al motore di elaborazione. Spark legge continuamente da Kafka a piccoli blocchi (un nuovo blocco ogni 5 secondi), così l'elaborazione è quasi in tempo reale ma a carico controllato. Spark tiene traccia del punto di lettura raggiunto: se si riavvia, riprende esattamente da dove era rimasto, senza rileggere né saltare dati.

3. Elaborazione distribuita. All'interno di Spark il blocco di dati viene smistato per nodo sui tre worker, che lavorano in parallelo. Qui i dati vengono prima salvati grezzi, poi ripuliti dai valori palesemente errati, infine arricchiti con il rilevamento di anomalie e con la segnalazione degli incendi (descritti nel capitolo 5).

4. Dalla elaborazione all'archiviazione. I risultati vengono scritti verso due archivi diversi e complementari: il database documentale conserva lo storico completo e gli stati, mentre il motore di ricerca conserva le serie temporali pronte per essere interrogate dalle dashboard.

5. Dall'archiviazione alla visualizzazione. Grafana interroga il motore di ricerca e mostra cruscotti che si aggiornano ogni pochi secondi: stato di ogni nodo, andamento dei sensori, anomalie e mappa degli incendi.

Va sottolineato che Spark esegue in realtà due flussi di lettura indipendenti sullo stesso insieme di dati: uno elabora le singole letture come descritto sopra; l'altro, in parallelo e con un proprio avanzamento separato, calcola riepiloghi su finestre temporali (capitolo 5.4). I due flussi non si disturbano a vicenda.

5. Come vengono trattati i dati in Spark

Per ogni blocco di dati in arrivo, il motore esegue una sequenza di passaggi. L'ordine è importante: prima si conserva il dato originale, poi lo si pulisce, infine lo si arricchisce.

5.1 Conservazione del dato grezzo

Il blocco viene subito salvato così com'è nel database documentale: è lo storico immutabile, la base su cui qualunque rielaborazione futura può ripartire. Per evitare che cresca all'infinito, questi dati vengono conservati per un periodo limitato e poi scadono automaticamente.

5.2 Pulizia

Vengono scartate le letture fisicamente impossibili (per esempio valori di CO o di gas fuori da ogni scala plausibile), che indicano un errore del sensore. Sono escluse prima dell'analisi per non falsare i risultati.

5.3 Rilevamento di anomalie

Il rilevamento usa due meccanismi che lavorano in parallelo e si completano a vicenda.

- **Confronto con il comportamento normale del sensore.** Per ciascun sensore il sistema impara progressivamente qual è il valore tipico e quanto questo oscilla, aggiornando questa conoscenza lettura dopo lettura senza dover riesaminare tutto lo storico. Quando una nuova lettura si discosta troppo dal comportamento abituale, viene segnalata come anomala. La misura del distacco distingue anche se il valore è insolitamente alto o insolitamente basso: utile, per esempio, a riconoscere un picco da un guasto. Questa conoscenza appresa viene salvata, così sopravvive ai riavvii del sistema.
- **Soglie assolute tarate sui dati reali.** In parallelo, alcune soglie fisiche segnalano subito condizioni pericolose: CO troppo alto, fumo elevato, temperatura sopra i 35 °C, oppure

resistenza del gas troppo bassa. Queste soglie coprono i casi in cui il confronto statistico non è ancora affidabile (le prime letture, quando la storia è troppo poca) o quando i valori sono tutti strutturalmente alti.

Una lettura è considerata anomala se scatta almeno uno dei due meccanismi.

5.4 Segnalazione degli incendi

Un evento incendio viene registrato solo nel momento della transizione, cioè quando un nodo passa da “nessun incendio” a “incendio”, e non a ogni singola lettura in cui l'incendio è in corso. Questo evita di riempire l'archivio di segnalazioni ripetute e mantiene un registro pulito dei soli eventi rilevanti. È inoltre predisposto, in modo opzionale, l'invio di una notifica esterna (webhook) al verificarsi della transizione; l'invio avviene in modo asincrono, così da non rallentare mai l'elaborazione.

5.5 Riepiloghi su finestre temporali

Il secondo flusso di Spark raggruppa le letture in finestre temporali di un minuto e calcola, per ciascun nodo, i valori medi, massimi e minimi dei sensori in quella finestra. Il sistema gestisce correttamente anche i dati che arrivano leggermente in ritardo, attendendo un margine prima di considerare chiusa una finestra. È l'esempio tipico di analisi basata sul tempo dell'evento, non sul tempo di arrivo.

6. Dove finiscono i dati: architettura Lambda

La persistenza è organizzata secondo l'architettura Lambda, che affianca due percorsi: un percorso veloce, sempre attivo, che serve i dati in tempo quasi reale; e un percorso batch, su richiesta, che analizza a freddo l'intero storico. La Tabella 3 mostra le diverse destinazioni dei dati.

Percorso	Destinazione	Contenuto
Veloce — dato grezzo	MongoDB	ogni lettura, prima della pulizia
Veloce — dato elaborato	MongoDB	letture arricchite con anomalie e segnalazioni
Veloce — serie storiche	Elasticsearch	andamenti dei sensori per le dashboard
Veloce — stato live	Elasticsearch	un riepilogo per nodo, sempre aggiornato
Veloce — finestre	Elasticsearch	riepiloghi al minuto per nodo
Stato interno	MongoDB	conoscenza appresa e statistiche cumulative
Eventi	MongoDB	solo le transizioni di incendio
Batch — analisi storica	MongoDB (+ copia su Elasticsearch)	percentili, andamenti orari, validazione, correlazioni

Tabella 3 — Le destinazioni dei dati nei due percorsi (speed e batch).

Complessivamente i dati sono distribuiti su sei collezioni del database documentale e cinque indici del motore di ricerca. I due archivi hanno ruoli diversi e complementari: il database documentale è la fonte di verità e lo storico, il motore di ricerca è ottimizzato per le interrogazioni temporali che alimentano i cruscotti.

6.1 Il percorso batch (analisi storica)

Un'elaborazione separata, avviata su richiesta, rilegge l'intero storico grezzo e calcola analisi che il flusso in tempo reale non può produrre, perché richiedono di vedere tutti i dati insieme: i percentili e gli andamenti tipici per nodo, le correlazioni tra i diversi sensori (per capire quali grandezze si muovono insieme durante la combustione) e la validazione del rilevamento. Il risultato è uno snapshot che viene riscritto a ogni esecuzione. Tenere questo percorso separato e su richiesta evita di occupare risorse in modo permanente quando non serve.

7. Validazione del rilevamento

La bontà del rilevamento viene misurata, nel percorso batch, confrontando ciò che il sistema avrebbe segnalato con la verità di riferimento data dal campo Fire, separatamente per ogni nodo. Il confronto si basa sulla regola fisica di incendio (valori di CO, fumo, temperatura o gas oltre soglia), non sulla segnalazione generica di anomalia: in questo modo non vengono contate come errori le anomalie statistiche che non hanno a che fare con un incendio, ottenendo una misura più fedele della reale capacità di rilevare il fuoco.

Da questo confronto il sistema ricava le metriche classiche di valutazione — precisione, recupero (recall), loro media armonica e accuratezza — per ciascun nodo. Il nodo_4, privo di etichetta, è escluso. I valori numerici dipendono dalla quantità di dati accumulata al momento dell'analisi, dato che i nodi girano in loop continuo, e vengono prodotti dal percorso batch e mostrati nella dashboard storica.

8. Le dashboard

La visualizzazione è affidata a Grafana, che interroga il motore di ricerca e mostra cruscotti aggiornati ogni pochi secondi. Le dashboard sono quattro, configurate automaticamente all'avvio del sistema (senza alcuna impostazione manuale), e coprono tre livelli di lettura: la vista d'insieme su tutti i nodi, l'approfondimento sul singolo nodo, la collocazione geografica degli incendi e l'analisi storica a freddo. La Tabella 4 le riassume; i paragrafi seguenti descrivono i contenuti di ciascuna.

Dashboard	Pannelli	A cosa serve
Vista globale	12	colpo d'occhio sullo stato e sugli andamenti di tutti e quattro i nodi
Dettaglio per nodo	25	approfondimento completo su un singolo nodo selezionabile
Mappa incendi	5	posizione geografica dei nodi e loro stato, in tempo reale
Vista storica	7	esito dell'analisi batch sull'intero storico

Tabella 4 — Le quattro dashboard e il loro scopo.

8.1 Vista globale (IoT Sensor Dashboard)

È la dashboard principale, pensata per avere in un colpo d'occhio la situazione di tutti i nodi. In alto quattro riquadri di stato, uno per nodo, mostrano se il nodo è in condizione di incendio o normale. Sotto, una serie di grafici nel tempo confronta i quattro nodi sulle grandezze più significative per il rilevamento — temperatura, CO, fumo e gas — così da cogliere subito un andamento anomalo. Completano la vista un contatore delle anomalie degli ultimi 15 minuti, un grafico dell'attività degli incendi nel tempo, una tabella con gli ultimi eventi anomali e un grafico delle temperature medie calcolate sulle finestre di un minuto.

8.2 Dettaglio per nodo (IoT Node Detail)

È la dashboard più ricca e serve ad approfondire un singolo nodo, selezionabile dall'alto. È organizzata in sezioni tematiche. Una prima fascia di riquadri riassume lo stato attuale del nodo: condizione di incendio, anomalie attive e valori istantanei di temperatura, CO, fumo e umidità. Seguono i grafici nel tempo di tutti i sensori, inclusi quelli ambientali (umidità, pressione, UV, luce visibile) oltre a quelli legati alla combustione. Una sezione dedicata mostra l'andamento dello scostamento dal comportamento normale per i quattro sensori chiave, utile a capire quando e quanto una grandezza si è discostata dalla sua norma. Una tabella elenca le ultime letture del nodo. Infine una sezione storica, alimentata dal percorso batch, riporta i valori minimi e massimi mai registrati e il totale delle letture elaborate.

8.3 Mappa incendi (Mappa Incendi)

Colloca i quattro nodi su una mappa geografica reale e ne mostra lo stato in tempo reale. Tre riquadri in alto contano quanti nodi sono, rispettivamente, in incendio, in anomalia o normali. Al centro la mappa vera e propria posiziona i nodi come marker colorati secondo il loro stato (verde per normale, arancione per anomalia, rosso per incendio) e si aggiorna ogni pochi secondi; da un marker si possono leggere i dati del nodo e passare alla dashboard di dettaglio. Una tabella affianca la mappa con lo stato testuale di tutti i nodi.

Nota metodologica. I sensori fisici non dispongono di GPS: le coordinate usate sulla mappa sono fittizie, assegnate a una zona boschiva a est di Cagliari (massiccio dei Sette Fratelli). La mappa di sfondo è reale ed è funzionale a livello dimostrativo; questo è dichiarato anche nella descrizione della dashboard.

8.4 Vista storica (IoT Storico — Batch Layer)

Mostra l'esito del percorso batch, cioè le analisi calcolate a freddo sull'intero storico. Una tabella riporta, per ciascun nodo, i valori tipici dei sensori espressi come percentili (i livelli sotto cui ricade la maggior parte delle letture) e la media. Altri pannelli descrivono la copertura dei dati raccolti per nodo (quantità di letture e arco temporale coperto) tramite tabelle e barre di confronto. Una sezione dedicata presenta le metriche di validazione del rilevamento per nodo (precisione, recupero e loro media armonica), confrontate con la verità di riferimento. Infine due tabelle mostrano le correlazioni tra i sensori: quelle chiave per ogni nodo e la matrice completa che mette in relazione tutte le grandezze tra loro, utile a capire quali sensori si muovono insieme durante la combustione.

9. Sintesi

Il progetto realizza una pipeline Big Data completa che mette in pratica i principi del corso, con particolare attenzione alla distribuzione dei componenti e al movimento dei dati:

- **Sorgenti distribuite e parallele:** quattro nodi indipendenti, una partizione del broker ciascuno, con ordine garantito per nodo.
- **Elaborazione realmente distribuita:** un cluster di elaborazione con tre worker, su cui gira la logica per nodo, senza riportare i dati di dettaglio a un punto unico.
- **Tolleranza ai guasti:** i messaggi sono replicati su tre broker; il sistema regge la perdita di un nodo del broker senza perdere dati.
- **Ripartenza senza perdite:** il sistema ricorda il punto di lettura e la conoscenza appresa, quindi un riavvio riprende esattamente da dove si era interrotto.
- **Due percorsi complementari:** un percorso veloce in tempo quasi reale e un percorso batch sull'intero storico (architettura Lambda).
- **Archiviazione poliglotta:** un database documentale come storico e fonte di verità, un motore di ricerca per le serie temporali che alimentano le dashboard.

Il codice e la configurazione completa (orchestrazione, job di elaborazione, dashboard) sono disponibili nel repository a corredo di questa relazione.